

Exercício 7 - Classificador de Bayes

Rodrigo Machado Fonseca - 2017002253

December 19, 2021

1 Introdução

Neste trabalho iremos implementar o algoritmo Classificador de Bayes 3. Em seguida, iremos utilizá-lo para classificar um conjunto de amostras.

2 Regra de Bayes

A regra de Bayes descreve a probabilidade de um evento, baseado em um conhecimento a priori que pode estar relacionado ao evento. Ela pode ser resumida na seguinte equação:

$$P[A/B] = \frac{P[B/A]P[A]}{P[B]} \quad (1)$$

onde $P[A/B]$ é a probabilidade de acontecer A dado que B aconteceu, $P[B/A]$ é a verossimilhança e os termos $P[A]$ e $P[B]$ são chamadas de probabilidades marginais. Conhecendo as probabilidades marginais e a verossimilhança, podemos inferir sobre a outra probabilidade condicional. Isto nos permite avaliar a validade de um evento uma vez que outro foi observado.

3 Classificador de Bayes

Baseado no que foi explicitado na seção 2 iremos implementar um classificador de bayes de acordo com as seguintes regras:

- Calcular $P[A]$ e $P[B]$.

- Escolher um elemento para ser classificado.
- Calcular a Verossimilhança.
- Classificar o elemento.

O código implementado é mostrado a seguir:

```
> rm(list=ls())
> calc_vero <- function(x1, x2, m1, m2, s1, s2, covc){
+   ro <- covc/sqrt((s1^2)*s2^2)
+   aux1 <- (2*pi*s1*s2*sqrt(1-ro^2))^-1)
+   aux2 <- -1*(2*(1-ro^2))^-1)
+   aux3 <- ((x1-m1)/s1)
+   aux4 <- ((x2-m2)/s2)
+   aux5 <- -2*ro*aux3*aux4
+   pdf <- aux1*exp(aux2*(aux3^2 + aux5 + aux4^2))
+   return(pdf)
+ }

> bayes_paramaters <- function(x){
+   c1 = x[x[,3] == 0, ]
+   c2 = x[x[,3] == 1, ]
+   m1c1 = mean(c1[,1])
+   m2c1 = mean(c1[,2 ])
+   s1c1 = sd(c1[,1])
+   s2c1 = sd(c1[,2])
+   covc1 = cov(c1[, 1], (c1[,2]))
+
+   m1c2 = mean(c2[, 1])
+   m2c2 = mean(c2[, 2])
+   s1c2 = sd(c2[,1])
+   s2c2 = sd(c2[,2])
+   covc2 = cov(c2[,1], (c2[,2]))
+   par_c1 <- c(m1c1, m2c1, s1c1, s2c1, covc1)
+   par_c2 <- c(m1c2, m2c2, s1c2, s2c2, covc2)
+   return(list(par_c1, par_c2))
+ }
```

```
> bayes_classifier <- function(x_train, x_test){  
+   parameters <- bayes_paramaters(x_train)  
+   par_c1 <- parameters[[1]]  
+   par_c2 <- parameters[[2]]  
+   y <- c()  
+   for(i in 1:nrow(x_test)){  
+     k1 <- calc_vero(x_test[i, 1],  
+                     x_test[i, 2],  
+                     par_c1[1],  
+                     par_c1[2],  
+                     par_c1[3],  
+                     par_c1[4],  
+                     par_c1[5])  
+     k2 <- calc_vero(x_test[i, 1],  
+                     x_test[i, 2],  
+                     par_c2[1],  
+                     par_c2[2],  
+                     par_c2[3],  
+                     par_c2[4],  
+                     par_c2[5])  
+     if(k1/k2 >= 1){  
+       y <- c(y, 0)  
+     }  
+     else{  
+       y <- c(y, 1)  
+     }  
+   }  
+   return(y)  
+ }
```

4 Exercício 1

A priori, iremos construir duas classes a partir de uma distribuição normal. A classe C1 terá o centro em (2, 2) e desvião padrão igual a 0.8 e a classe C2 terá o centro em (4, 4) e com desvião padrão 0.4, como mostrado na figura 1.

Uma vez definido as amostras, iremos separar 90% para construir o mod-




Figure 1: Dados amostrados de duas distribuições Normais com médias $m1 = (2; 2)^T$ e $m2 = (4; 4)^T$ e coeficiente de correlação nulo.

elo e 10% para treinar o modelo. O gráfico 2 mostra os dados de treinamento e teste antes da classificação.

```
> x <- rbind(c1, c2)
> index <- sample(1:nrow(x), length(1:nrow(x)))
> x <- x[index,]
> training_sample_number = round(nrow(x)*0.9)
> x_train <- x[1:training_sample_number,]
> x_test <- x[(training_sample_number+1):nrow(x), ]
> y_hat <- bayes_classifier(x_train, x_test)
> acuraccy <- 1 - sum(abs(y_hat - x_test[,3]))/length(y_hat)
```

Uma vez feita a classificação, mostramos abaixo o percentual de acertos




Figure 2: Gráfico com amostras de treinamento e amostras de teste não classificadas




Figure 3: Superfície de separação

do conjunto de teste:

```
> print(100*acuraccy)
```

[1] 100

Por fim, o gráfico 3 mostra a superfície de separação gerada com o classificador construído para o problema.

5 Exercício 2

Agora os dados de entrada devem ser amostrados de quatro gaussianas, como mostrado na figura 4. Para todas as gaussianas foi adotados desvio padrão igual a 0.4.




Figure 4: Problema XOR

Uma vez definido as amostras, iremos separar 90% para construir o modelo e 10% para treinar o modelo. O gráfico 5 mostra os dados de treinamento e teste antes da classificação.

```
> set.seed(0)
> x <- cbind(x, y)
> index <- sample(1:nrow(x), length(1:nrow(x)))
> x <- x[index,]
> training_sample_number = round(nrow(x)*0.9)
> x_train <- x[1:training_sample_number,]
> x_test <- x[(training_sample_number+1):nrow(x), ]
> y_hat <- bayes_classifier(x_train, x_test)
> acuraccy <- 1 - sum(abs(y_hat - x_test[,3]))/length(y_hat)
```

Uma vez feita a classificação, mostramos abaixo o percentual de acertos do conjunto de teste:

```
> print(100*acuraccy)
```

```
[1] 98.75
```

Por fim, o gráfico 6 mostra a superfície de separação gerada com o classificador construído para o problema.

6 Conclusão

É possível perceber que o problema número 2 obteve menor acurácia. Este problema divide o espaço em quatro regiões, onde cada região possui um centro (centro da gaussiana). Já no problema anterior o espaço era dividido em 2 regiões, com um centro cada. Em ambos os problemas, podemos visualizar os centros como vértices de um quadrado. No caso do primeiro problema, a distância entre os 2 centros é a diagonal deste quadrado. Para o segundo problema, as duas classes adicionadas nos vértices remanecentes fazem com que agora tenha duas classes mais próximas com distância igual ao lado do quadrado. Portanto, a distância entre os centros mais próximos se reduziu. Devido aos fatores supracitados, é possível afirmar que no segundo problema as amostras devem possuir menor grau de liberdade para se manterem no quadrante correto, porque o espaço possui mais centros e a distância entre




Figure 5: Gráfico com amostras de treinamento e amostras de teste não classificadas

os centros mais próximos é menor. Por esse motivo, a probabilidade de se existir uma superposição de classes é maior, o que torna a solução um pouco mais complexa. Isso reflete a menor acurácia encontrada no problema 2. De qualquer maneira, essa acurácia, ainda que menor, permanece muito próxima de 100%.

A geração dos gráficos com as amostras de teste classificadas e com a superfície de separação também foram relevantes para ilustrar a eficiência do classificador e observar seu comportamento em todo o espaço do gráfico.

Com o experimento foi possível compreender melhor o funcionamento do classificador de Bayes e implementá-lo de forma satisfatória. Os resultados obtidos podem provar que o classificador de Bayes tem desempenho muito bom para os problemas de classificação tratados nesse exercício.




Figure 6: Superfície de separação